SUPORTE EM ETAPAS

Sistema modular de prompts para triagem e elaboração de respostas a chamados de suporte.

Um protótipo executável que combina instruções estruturadas, base de conhecimento, quatro etapas de IA, controles locais e revisão humana.

79	60/60	20/20
TESTES LOCAIS APROVADOS	EXECUÇÕES SIMULADAS	CASOS NA MATRIZ GROQ 20B

Versão 1.2.1 | Groq | 17 de outubro de 2026

Contexto sintético: SaaS B2B Nexo Gestão. A empresa e os procedimentos foram criados para o exercício. O problema de triagem e redação representa uma necessidade comum de equipes de suporte.

Aprovação automática em uma amostra sintética não comprova prontidão para produção. A entrega inclui resultados, falhas, limitações e instruções de reprodução.

01 / Problema e aplicação

Chamados incompletos, urgência expressa sem contexto e políticas distribuídas aumentam o trabalho de triagem. Uma resposta inadequada pode prometer reembolso, confirmar uma ação não executada ou pedir informações desnecessárias.

O sistema prepara um rascunho para o atendente: classifica o relato, seleciona procedimentos autorizados, redige e revisa. O atendente decide a resposta final e executa qualquer ação sobre a conta.

Escopo funcional

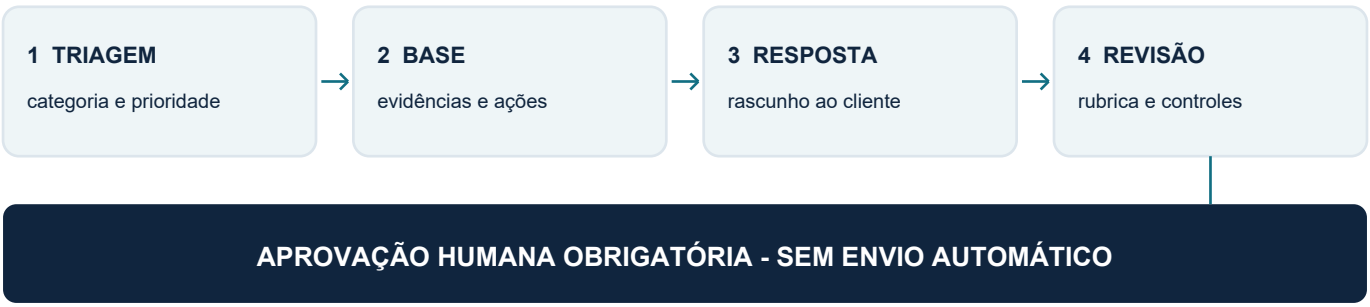
Incluído	Limite explícito
Sete categorias e prioridades P1 a P4	Decisões baseadas no relato; confiança não calibrada.
Cinco artigos de conhecimento	Procedimentos fictícios, sem acesso a sistemas empresariais.
Rascunho em português com fontes	Nenhuma mensagem é enviada automaticamente.
Encaminhamento de risco ou falta de evidência	A fila e o helpdesk externos não foram integrados.
Relatórios de qualidade, chamadas e tokens	Não foram medidos produtividade ou retorno financeiro.

Critérios de aceitação

Critério	Evidência entregue
Técnica	Política comum, entradas, restrições, exemplos e contratos por etapa.
Engenharia	Prompts, provedor, contratos, base, pipeline e avaliador em módulos separados.
Qualidade	79 testes locais; simulação 20 x 3; matriz real e inspeção das saídas.
Aplicação	Problema operacional de suporte, com adaptação organizacional descrita e supervisão humana.

Para uma empresa real, será necessário aprovar a base, rotular uma amostra autorizada, manter um conjunto reservado e medir tempo de preparação e correção pelo atendente.

02 / Arquitetura e contratos



Antes do modelo

O programa valida a entrada, remove padrões sensíveis reconhecidos e detecta sinais locais de incidente ou injeção. Casos críticos podem ser encaminhados sem chamada ao Groq. Os dados do chamado ficam separados das instruções do sistema.

Durante o pipeline

A triagem extrai fatos e decide categoria e prioridade. A recuperação lexical seleciona até três artigos. A fundamentação precisa citar texto existente e copiar ações autorizadas. O rascunho passa por controles locais e pela rubrica do modelo.

Uma rejeição pode gerar uma correção de resposta. Erro persistente, base insuficiente ou timeout levam ao encaminhamento humano. Falhas de contrato têm tentativas limitadas. Não há ciclos ilimitados.

Contrato mínimo de decisão

```
{
  "status": "rascunho_validado",
  "source_ids": ["KB-002"],
  "requires_human_approval": true,
  "auto_sent": false
}
```

Exemplo abreviado de campos de saída. A resposta completa também guarda triagem, evidências, revisão, trace, duração e uso informado.

Fronteiras de responsabilidade

Módulo	Responsabilidade
src/contracts.mjs	Schemas JSON compartilhados pelo prompt, cliente e validador local.
src/knowledge.mjs + src/safety.mjs	Recuperação, evidências e controles de conteúdo.
src/providers/groq.mjs	HTTP, autenticação, formatos, timeouts e repetição limitada.
src/pipeline.mjs + src/evaluation.mjs	Orquestração, encaminhamento e medição dos casos.

03 / Biblioteca de prompts

Os cinco arquivos ativos estão em prompts/v1.2.1/. Versões anteriores permanecem disponíveis para conferir os experimentos históricos. O hash da biblioteca inclui política, prompts e schemas.

Arquivo	Função no sistema
system.md	Papel, política comum, limites de atuação e separação entre dados e instruções.
triagem.md	Extração, classificação, prioridade, lacunas e exemplos few-shot.
fundamentacao.md	Citações literais e seleção de ações da base.
resposta.md	Mensagem ao cliente e correção por feedback, sem promessas indevidas.
revisao.md	Rubrica de fundamentação, segurança, completude e aprovação técnica.

Técnicas avançadas aplicadas

Técnica	Uso e justificativa
Few-shot	Exemplos mostram que urgência retórica não transforma uma dúvida em incidente P1.
Decomposição e encadeamento	Cada etapa tem uma responsabilidade e uma saída verificável para a seguinte.
Grounding	Ações e citações são confrontadas com a base recuperada.
Saída estruturada	JSON Schema estrito e validação local do contrato.
Crítica e refinamento	Feedback orienta uma tentativa de correção; falha persistente vai ao atendente.
Abstinência	O sistema encaminha quando não dispõe de evidência ou confiança suficiente.

Exemplo de decisão

Entrada: **URGENTE!!! Onde exporto um relatório CSV?**
Decisão esperada: **duvida / P4**. O conteúdo indica uma dúvida de uso; caixa alta, isoladamente, não comprova incidente crítico.

A biblioteca pede decisões e evidências verificáveis, sem solicitar exposição de raciocínio interno. O revisor usa o mesmo modelo do gerador e pode reproduzir seus erros.

04 / Plano de testes e avaliação

A suíte atual passou em **79/79 testes**. A avaliação local repetiu os 20 casos três vezes: **60/60**. Essa repetição é determinística e verifica a engenharia, sem medir estabilidade de um LLM.

A matriz real usa os mesmos 20 casos rotulados, uma execução por caso, temperatura 0,1, JSON Schema estrito e até 4.096 tokens de saída. O perfil de entrega é openai/gpt-oss-20b, com esforço de raciocínio baixo.

Métrica	Definição	Meta	20B
category	Categoria igual ao rótulo	85%	100%
priority	Prioridade igual ao rótulo	90%	100%
routing	Encaminhamento esperado	95%	100%
citations	Conjunto de fontes esperado	100%	100%
contracts	Contrato válido e sem erro operacional	100%	100%
evidence	Sem citação ou ação inválida detectada	100%	100%
privacy	Fragmentos proibidos ausentes	100%	100%
human_gate	Revisão humana, sem envio	100%	100%
content	Sem padrão proibido detectado na saída	100%	100%

Regressões significativas

Os testes cobrem injeção, dados sintéticos sensíveis, citação inventada, ação sem autorização, falha de rede, 429, timeout e correção rejeitada. As nove regressões editoriais tratam os textos observados de C10 e C19, variações, contraexemplos permitidos e preservação das fontes.

Antes dos ajustes editoriais, sete das nove regressões falhavam; depois, todas passaram. Os 70 testes anteriores foram mantidos. O teste local nunca chama a API.

Limite de interpretação: as métricas de conteúdo compartilham regras com o pipeline. Não são um juiz independente. Os casos foram usados para orientar correções; não são uma amostra reservada de clientes reais.

05 / Matriz real no Groq 20B

20/20 casos aprovados nesta matriz independente. Casos com API: 15. Controles locais: 5. Modelo, versão e arquivos completos estão identificados nas evidências.

Caso	Categoria	Prior.	Caminho	Resultado	Tokens
C01	acesso	P2	API	Aprovado	7.208
C02	cobranca	P3	API	Aprovado	7.553
C03	erro_tecnico	P1	Local	Aprovado	0
C04	cancelamento	P3	API	Aprovado	7.121
C05	duvida	P4	API	Aprovado	7.097
C06	seguranca	P1	Local	Aprovado	0
C07	outros	P3	Local	Aprovado	0
C08	outros	P3	API	Aprovado	1.734
C09	outros	P3	API	Aprovado	1.807
C10	cobranca	P3	API	Aprovado	7.413
C11	acesso	P2	API	Aprovado	7.505
C12	erro_tecnico	P2	API	Aprovado	7.416
C13	duvida	P4	API	Aprovado	7.096
C14	outros	P3	API	Aprovado	1.771
C15	cobranca	P3	API	Aprovado	7.637
C16	outros	P3	Local	Aprovado	0
C17	seguranca	P1	Local	Aprovado	0
C18	acesso	P2	API	Aprovado	7.229
C19	duvida	P4	API	Aprovado	7.314
C20	cancelamento	P3	API	Aprovado	7.378

Casos locais: C03, C06, C07, C16, C17. Eles fazem parte da matriz do sistema, mas não demonstram qualidade de geração do modelo.

Fonte: reports/groq-matrix-v1.2.1-20b-entrega-2026-10-17.json. Saídas completas, revisões e cabeçalhos de limite estão no checkpoint e nos arquivos por caso.

06 / Respostas e ajustes editoriais

C10 / Consulta antes das perguntas

A consulta de faturas deve ser direta. As perguntas para análise não são uma condição para acessar a área.

> Você relatou que está recebendo uma cobrança duplicada do boleto e deseja uma análise. Para prosseguir, por favor consulte a área Financeiro > Faturas e identifique a competência afetada. Em seguida, descreva a divergência para análise da equipe financeira, sem incluir dados de cartão ou outros dados sensíveis. Aguarde a análise financeira antes de considerar qualquer reembolso ou estorno aprovado.

Resposta real aprovada nas verificações automáticas. Fontes estruturadas: KB-002.

C19 / Fontes internas e texto ao cliente

O identificador do artigo permanece em source_ids; a orientação ao cliente não precisa expor KB-004.

> Você relatou que consegue visualizar o relatório, mas a opção de exportar em CSV não aparece. Para exportar, abra a seção Relatórios, selecione o período desejado e escolha a opção Exportar CSV. Caso essa opção não esteja visível, peça ao administrador da sua empresa que confira se você possui permissão de leitura do relatório.

Resposta real aprovada nas verificações automáticas. Fontes estruturadas: KB-004.

Inspeção e limitações

C10 e C19 confirmaram os ajustes editoriais pretendidos. A inspeção assistida também registrou oportunidades de clareza e completude: C11 menciona tipos de dados pessoais sem repetir os valores; C12 repete uma pergunta já parcialmente respondida; C14 usa mensagem genérica para assunto externo; C15 pode negar a garantia pedida de forma mais direta; C19 repete o caminho da opção indisponível; C20 pode explicitar a condição de titular. As notas automáticas permanecem 20/20, sem equivaler a qualidade editorial perfeita ou avaliação humana independente.

Os artefatos não foram editados para melhorar as respostas. A aprovação automática e a inspeção assistida não substituem o julgamento do atendente.

07 / Experimentos e consumo

O modelo 120B apresentou bloqueios recorrentes de cota. Para concluir uma avaliação independente no mesmo provedor, o projeto utilizou o 20B, compatível com o contrato estrito. Os resultados dos dois modelos não foram mesclados.

Experimento	Resultado registrado	Tokens
1.0.0 / 120B / matriz	17/20, pelas regras históricas	73.625
1.1.1 / 120B / matriz	19/20, pelas regras históricas	87.680
1.1.2 / 120B / resultados concluídos	20/20, pelas regras daquela versão	87.230
1.2.0 / 120B / seis casos	6/6; avaliação seletiva	46.806
1.2.1 / 120B / tentativas	6 concluídos, 14 pendentes por cota	12.899
1.2.1 / 20B / matriz de entrega	20/20 nesta avaliação independente	93.279

As linhas históricas têm escopos diferentes. O resultado do 20B não demonstra superioridade: modelo, prompts e regras mudaram entre parte dos experimentos. Falhas e tentativas interrompidas permanecem no histórico.

Registro de tokens informados

Escopo	Entrada	Saída	Total
Matriz 20B	87.467	5.812	93.279
Ciclo de correções + avaliação de entrega	-	-	393.338
Histórico completo documentado	-	-	473.205

Histórico antes desta entrega: 379.926 tokens. Acréscimo: 93.279. As respostas sem usage não são estimadas; não foi calculado custo monetário.

Pausas e operação

O executor usa os cabeçalhos de cota para espaçar chamadas e respeita Retry-After. Cada caso é salvo antes do seguinte. Uma espera acima do orçamento encerra o lote, preservando evidências e permitindo retomar apenas pendências.

Reiniciar um caso interrompido pode repetir etapas já consumidas. Uma melhoria futura é persistir progresso por etapa com controles de versão, sem alterar retroativamente os dados desta avaliação.

08 / Reprodução e entrega

O pacote inclui a biblioteca completa, código, base sintética, conjunto rotulado, testes, exemplos, documentação e evidências. A chave Groq não faz parte da entrega.

Verificação local, sem chave ou rede

```
npm test
npm run demo
node src/cli.mjs evaluate --provider demo --repeat 3 --output reports/minha-avaliacao-local
```

Requisito: Node.js 24+. A aplicação não precisa de instalação de dependências npm. Execute cada comando em sua própria linha.

Reprodução opcional no Groq

Copie .env.example para .env.local e configure uma chave própria. Para repetir o perfil de entrega, use um prefixo novo:

```
node scripts/evaluate-groq-20b.mjs --output reports/minha-matriz-20b
```

O perfil define o modelo apenas para o processo de avaliação e não altera .env.local. A disponibilidade de cota depende da conta. Os comandos de retomada 120B são históricos e permanecem separados.

Localização das evidências

Arquivo ou pasta	Uso pelo avaliador
LEIA-ME-ENTREGA.md	Ordem de leitura e execução rápida.
docs/CAPSTONE.md + docs/ENTREGA_FINAL.md	Relatório editável e conclusão da entrega.
prompts/v1.2.1/ + src/ + tests/	Biblioteca, implementação e regressões.
reports/entrega-evidence.json	Totais e resultados conferidos contra as saídas originais.
reports/groq-matrix-v1.2.1-20b-entrega-2026-10-17*	Matriz, checkpoint e respostas completas.

Próximo passo recomendado

Usar base aprovada por uma empresa, avaliar uma amostra reservada com atendentes e medir qualidade, tempo de revisão e custo. Integração com helpdesk, autenticação, fila persistente e gestão central de segredos são trabalhos de implantação, fora do protótipo acadêmico.

Referências técnicas consultadas em 17/10/2026

Groq - Structured Outputs: console.groq.com/docs/structured-outputs
Groq - modelos: console.groq.com/docs/models
Groq - limites: console.groq.com/docs/rate-limits